Dokumentace úlohy XQR: XML Query v PHP 5 do IPP 2014/2015

Jméno a příjmení: Tomáš Coufal

Login: xcoufa09

Úvod

Pro první část kurzu IPP – projekt v PHP mi bylo zadáno XQR, neboli XML query. Principem je aplikace SQL dotazu, definovaného buď jako parametr při volání nebo předaného v souboru, na vstupní XML soubor. Tyto data jsou programu předána na standardní vstup či parametrem a po zpracování jsou poslána buď na standardní výstup nebo do souboru. Dále program dovoluje generovat (nebo generování zakázat) XML hlavičky a obalovat výsledná data do tzv. ROOT tagu. Z časových důvodů nebyla implementována žádná rozšíření.

Skript se skládá z několika částí a to: Zpracování parametrů, Analýza SQL dotazu, Aplikace SQL dotazu. O těchto částech viz. níže. Dále program obsahuje také funkce pro čtení a zápis z a do souboru, výpis hlášení či nápovědy: load_file(), dump_output(), extended_die(), print_help().

Zpracování parametrů

Pro zpracování parametrů z důvodů bezpečného zacházení s vícenásobným použitím téhož parametru není využita žádné prefabrikované řešení, ale vytvořeno vlastní. Parametry zpracovává funkce arg_parse(): vytvoří kopii globálního pole s argumenty a v cyklu je postupně od posledního zpracovává a odebírá z pole. Zpracování končí, zbývají-li v poli dva prvky: celé volání a název programu. Zpracované parametry jsou uloženy v asociativním poli. Nabízelo se také řešení vytvořit pro tato data samostatnou strukturu, ale z důvodů jednoduchosti bylo použito pole.

Analýza a zpracování SQL dotazu

Důležitou součástí skriptu je analýza SQL dotazu. To zabezpečuje funkce query_parse(), která na základě gramatiky definované v zadání rozdělí data ve SQL dotazu a uloží je do asociativního pole či případně vypíše chybové hlášení. Analýza gramatiky, správné sémantiky a syntaxe je vyřešena regulárními výrazy. Nejdřív se zkontroluje správné pořadí všech částí dotazu a tyto se následně vyhodnocují každá zvlášť:

Příslušná část SQL dotazu Regulární výraz

Kontrola syntaxe /(SELECT.*(LIMIT)?.*FROM.*(WHERE)?.*(ORDER BY)?.*)/

SELECT\s)(?:\s*).+?(?=\s+LIMIT\\s+FROM)/

SELECT ověření /\w*/

 $LIMIT /(? <= LIMIT \s)(?: \s^*). + (?= \s+FROM)/$

LIMIT ověření /\d*/

FROM /(?<=FROM\s)(?:\s*).*?(?=\s|\$)/

FROM ověření /\w*(?:\.)?\w+/

WHERE /(?<=WHERE\s)(?:\s*).*(?=\sORDER BY|\$)/

WHERE jednotlivé složky /^(?:\s*)((?:NOT\s+)*)(\w+)?(?:\.(\w+)?)?\s+(CONTAINS|=|>|<)\s+

(\\\"(?:.*)\\\"|-?\d+\b|\\\\"\\")\$/

ORDER BY /(?<=ORDER BY\s)\w+(?:\.\w+)|(?:ASC|DESC)\$/

Aplikace SQL dotazu na XML

Za druhou nosnou část skriptu je zodpovědná funkce proceed_query(). Ta se stará o správnou filtraci dat ve vstupním XML. K tomu využívá velmi schopné funkce z knihovny SimpleXML – funkce xpath(), která umožňuje adresování do XML. Postupně z XML tedy filtruji data, nejdřív část FROM, poté SELECT, WHERE a nakonec LIMIT – tedy volám xpath() čtyřikrát. Obzvláště skládání WHERE části je složité a také naráží na limitace xpath() tak, jak je v SimpleXML (XPath 1.0) definováno. Například neumí porovnávat řetězce. U LIMIT jsem zvažoval dvě různé možnosti řešení, buď zastavit hledání a generování po určitém počtu výsledků a nebo vyfiltrovat vše, a pak výsledek jen omezit na požadovaný počet a ten vypsat. Druhé řešení není vůbec optimální, protože při větším objemu bude pomalé nicméně je to řešení jednoduché na implementaci a proto bylo použito.